تمرین سوم درس مبانی داده کاوی

(بهار ۴۰۲)

مهلت تحویل تمرین: ۸ اردیبهشت ماه

سوالات تئوری

سوال ۱- برای ۸ مورد داده های p1 تا p8 و نیز خوشه بندی سلسله مراتبی شکل زیر مقدار F-measure سلسله مراتبی (hierarchical F-measure) را محاسبه نمایید. کلاس A شامل p1 ، p2 و p3 است و کلاس B شامل p4 تا p8 می باشد.

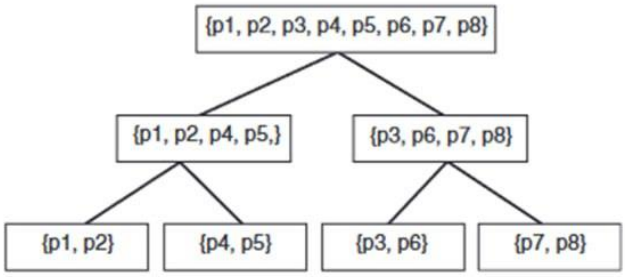

سوال ۲- یک مجموعه داده حاوی ۱۰۰ رکورد به شما داده می شود و از شما خواسته شده که داده ها را خوشه بندی کنید. شما از K-means برای خوشه بندی داده ها استفاده می کنید، اما به ازای تمام k های ممکن ({k = {1, 2, ..., 100) الگوریتم K-means تنها یک خوشه غیر خالی را بر می گرداند. سپس یک نسخه افزیشی از K-means را اعمال کنید، اما دقیقاً همان نتیجه قبلی را به دست می آورید. چه گونه چنین اتفاقی ممکن است؟ چگونه یک خوشه بندی single link یا DBSCAN می تواند چنین مشکلی را رفع کند؟

سوال ۳- با یک مثال نشان دهید که انتخاب مرکزهای تصادفی ممکن است در K-means باعث عملکرد ضعیف این الگوریتم خوشه بندی شود. اجرای چندگانه می تواند این مشکل را برطرف کند، اما گاهی ممکن است این کار نیز به خوبی عمل نکند. این مورد را نیز با یک مثال نشان دهید.

سوال ۴- هر دو الگوریتم K-means و K-medoids می توانند خوشه بندی موثری را انجام دهند. (تمرین ۱۰،۶ (سوال ۶ فصل دهم) کتاب اقای هان)

- قدرت و ضعف K-means را در مقایسه با K-medoids نشان دهید.
- قدرت و ضعف این طرح‌ها را در مقایسه با یک طرح خوشه بندی سلسله مراتبی (مانند AGNES) نشان دهید.

سوالات عملی

سوال ۵- دیتاست حملات قلبی بیماران (heart_diagnose.csv) یک بیمارستان در اختیار شما قرار گرفته است. در این دیتاست کوشیده شده است که احتمال حمله قلبی براساس سایر فیلد ها بیمار پیش بینی شود .

۱- گزارشی را از دیتاست بگیرید. (شامل اسم ستون، تعداد فیلد غیر null و تایپ و ...)
۲- فیلد های دسته ای را به روش one-hot به فیلد هایی عددی تبدیل کنید.
۳- به کمک تابع pca از کتابخانه sklearn تعداد فیچر ها را به دو فیچر کاهش دهید، آن را در یک دیتافریم مجزا ذخیره و در ادامه کار استفاده کنید.
۴- برای مقادیر k از ۱ تا ۲۰ الگوریتم K-means را اجرا کنید و نمودار SSE بر حسب k را رسم کنید. بر اساس روش elbow بگویید که کدام k مناسب تراست.
۵- برای مقادیر ۲ تا ۲۰ معیار silhouette را با روش K-means به دست آورید. نمودار میله ای معیار silhouette بر اساس k رسم کنید. همچنین بهترین k در این مرحله را بدست آورید.
۶- برای بهترین k که درقسمت های ۴ و ۵ بدست آورده اید خوشه بندی را انجام داده و نتیجه را به کمک scatter plot نشان دهید.
۷- برای هریک از خوشه های بدست آمده با بهترین مقدار K در قسمت ۶، تابع describe را فراخوانی و آن را توصیف کنید.

سوال ۶- با استفاده از مجموعه داده BankNote به سوالات زیر پاسخ دهید:

۱- مشابه سوال قبل قسمت های ۱ و ۳ را برای این دیتاست انجام دهید.

۲- به روش ward، نمودار Dendogram داده ها را رسم کنید و تعداد کلاستر مناسب را بدست آورید. (برای تمرین میتوانید درمورد دو روش دیگر complete, single نیز مطالعه نموده، آن را اعمال و نتایج آن را مقایسه کنید)

۳- برای مقادیر ۲ تا ۲۰ خوشه بندی به روش Agglomerative را انجام دهید، معیار silhouette را برای هر خوشه بدست آورده و نمودار میله ای ان را رسم کنید. در نهایت بهترین مقدار k برای خوشه بندی بدست آورید.

۴- برای بهترین k که در قسمت قبل بدست آوردید نمودار scatter را رسم کنید.

۵- هریک از خوشه های بدست آمده را با تابع describe توصیف کرده و با نتایج قسمت قبل مقایسه کنید. (صرفا نتیجه بدست آمده در تعداد کلاستر مورد نیاز و نمودار های scatter). (همچنین برای تمرین میتوانید قسمت های ۳ و ۴ را بر مبنای معیار elbow انجام دهید و نتایج را مقایسه کنید.)

۶- این بار از الگوریتم KElbowVisualizer استفاده کرده (واقع در کتابخانه yellowbrick.cluster) و نمودار معیار elbow بر حسب k را رسم کنید. مقدار بهترین k را بدست آورید. نتیجه خوشه بندی را به صورت scatter plot نشان دهید (راهنمایی :معیار eblow را براساس مدلی که از مدل Agglomerative نشان دهید. برای تمرین میتوانید همین معیار را برای الگوریتم K-means انجام دهید و خروجی نمودار های ElbowVisualizer را مقایسه کنید).

۷- یکی از روش های ارزیابی دقت کلاسترینگ ارزیابی به روش inertia_ است. برای تعداد کلاستر بین ۱ تا ۵ (به روش K-means) این معیار را محاسبه و سپس آن را روی یک نمودار scatter نشان دهید.

۸- این بار دیتاست اولیه را براساس tsne نرمالایز کرده و آن را در دو بعد نشان دهید.

۹- از الگوریتم DBScan استفاده کنید و نتیجه خوشه بندی را نشان دهید. می توانید الگوریتم را با پارامتر های مختلف انجام دهید (مثال: eps=1,min_samples=4 گرچه که نتیجه خیلی خوبی را به همراه ندارد). تاثیر مقادیر مختلف eps را بررسی کنید و درباره آن توضیح دهید. خروجی خوشه بندی (لیبل بندی داده) را به وسیله نمودار scatter plot نشان دهید.

۱۰- توسط الگوریتم NearestNeighbors از کتابخانه sklearn.neighbors میتوانید تخمین خود در مرحله قبل را بهبود ببخشید. از این کتابخانه استفاده کرده و پارامتر های dbscan را با آن تخمین بزنید (لزومی ندارد که تفکیک دقیقی بین کلاستر های موجود صورت بگیرد، صرفا نحوه کار با این کتابخانه مد نظر است).

نحوه تحویل: سوالات تئوری را به صورت تایپ شده و در قالب یک فایل PDF تحویل دهید. به علاوه هر یک از سوالات عملی را در قالب یک فایل ipynb به همراه نتایج قرار داده و فایل را به صورت Qn نام گذاری نمایید که n شماره سوال مربوطه می باشد. در انتها فایل های پایتون را به همراه فایل PDF تماما در قالب یک فایل zip نامگذاری شده به صورت NAME_STUDENTID در سامانه درس بارگذاری کنید. برای سوالات عملی توضیحات خود را به صورت Markdown در فایل پایتون بنویسید.

"If people valued life and love more than gold and power, the world would be a better place." - Thorin Oakenshield